

# 基于 OHLCV 数据的高波动标的收益率预测模型

## 摘要

本文针对金融市场中 30 支高波动标的的 1 分钟 OHLCV 数据，构建了一套包含多尺度价格、成交量、波动率和微观结构特征在内的完整特征体系，并提出了基于极端行情识别与分离回归融合的收益率预测框架。特征方面，以 60 分钟滑动窗口为基础，在 5 至 240 分钟共 7 个典型周期上计算约 490 维特征，全面刻画市场状态；所有特征均采用历史信息滚动的 Z-score 进行标准化，避免了未来信息泄露。模型方面，以 LightGBM 为基学习器，首先训练一个适度正则化的极端行情二分类器（叶子数 15、最大深度 4、L1/L2 分别为 3.0 和 5.0），输出当前市场的极端概率，随后分别训练正常行情和极端行情的收益率回归器，最终通过概率加权融合输出预测。针对不同预测时长，对 5 分钟收益率采用分离融合策略，对 60 分钟收益率则使用全量数据统一建模，以平衡样本量与信号强度。训练过程中对极端样本施以 3 倍权重，并采用 Huber 损失函数增强鲁棒性，训练/验证划分引入 30 分钟间隔以防止标签自相关泄露。在本地分片验证集上，以信息系数（IC）为核心指标，分别评估正常与极端行情下的表现。结果显示，极端分类器的 AUC 达到 0.912，5 分钟收益率在正常行情下的平均 IC 为 -0.025，极端行情下 IC 为 0.073；60 分钟收益率正常行情平均 IC 为 0.002，极端行情 IC 为 0.182。特征重要性分析表明，Ret5 分离模型的特异性使 KDJ 等动量指标获得较高增益，而 Ret60 统一模型则由波动率和微观结构特征主导，其中帕金森波动率、量价相关性及价格回撤等特征贡献最大。该模型具有无未来信息、内存高效和状态自适应等优点，尤其适用于高频波动市场中的极端收益预测场景。

# 1 问题重述与分析

## 1.1 问题背景

在金融市场中，高波动标的往往伴随着剧烈的价格变化和较高的交易风险，准确预测此类资产的短期与中长期收益率对量化交易、风险管理和投资决策均具有重要意义。本题从多个不同类型的交易市场中选取了 30 支具有代表性的高波动标的，提供了每支标的 1 分钟频率的 OHLCV（开盘价、最高价、最低价、收盘价、成交量）K 线数据。为提高不同价格量级标的之间的可比性，所有价格字段已经过统一的基准化处理。题目同时给出了未来 5 分钟与未来 60 分钟的收益率作为预测目标，并要求所建模型不仅要在普通行情下表现良好，还必须兼顾极端行情下的预测能力，鼓励进一步探索多市场、多标的的联合建模方法。

## 1.2 问题目标与分解

本题的核心任务是设计一套从原始 OHLCV 数据出发，到生成未来收益率预测结果的完整解决方案。该任务可自然分解为三个相互衔接的子问题：首先是特征工程，即如何从每秒钟更新的高维时间序列中提取具有预测能力且不引入未来信息的特征集合；其次是预测建模，即如何根据这些特征建立回归模型，并使得模型既能在平稳市场中保持精度，又能在市场剧烈波动时给出有参考价值的预测；最后是模型评估与验证，需要选择合适的评价指标来量化模型在不同行情下的表现，并通过对比实验验证所提方法的有效性。此外，题目留出的多市场联合建模方向也为我们进一步挖掘跨标的的共性信息提供了探索空间。

# 2 模型假设与合理性说明

任何数学模型都是对现实世界的抽象，合理的假设是连接问题实际与数学形式的桥梁。本文的基本假设包括以下几个方面。

第一，我们假设在样本数据覆盖的时间区间内，各交易市场的微观结构、交易机制和数据生成过程保持相对稳定，未发生由于政策干预、技术故障等原因造成的结构性断裂，这使得基于历史数据统计规律的学习方法能够成立。

第二，我们假设 OHLCV 数据中包含了市场情绪、流动性和趋势等方面的有效信息，通过适当的特征工程可以将其转化为对未来收益率的预测信号，即价格行为并非完全随机游走，而是存在可被模型捕捉的局部规律。

第三，极端行情虽然形式多样，但通常伴随着波动率急剧放大、成交量异常增长、价差快速扩大等共性微观特征，因此可以训练一个分类模型对其进行识别，这是分离融合策略的基础。

第四，虽然不同标的来自不同市场，但它们作为高波动资产，其价格行为在统计层面存在一定的共性，例如波动率聚集、尾部风险等，这保证了将所有标的混合训练统一模型具有合理性。

第五，我们承认原始数据中不可避免地含有噪声和异常值，但通过缩尾处理、Huber 损失函数和样本加权等手段，可以将其不利影响控制在可接受范围内。

# 3 符号说明

为便于后续表述，表1汇总了本文中使用的符号及其含义。

表 1: 主要符号说明

| 符号                                                      | 含义                           | 单位/备注             |
|---------------------------------------------------------|------------------------------|-------------------|
| $O_t, H_t, L_t, C_t, V_t$                               | 第 $t$ 分钟的开盘价、最高价、最低价、收盘价、成交量 | 价格已基准化            |
| $r_{t+k}$                                               | 未来 $k$ 分钟收益率                 | $k \in \{5, 60\}$ |
| $w$                                                     | 特征滚动窗口长度                     | 60 分钟             |
| $\mathbf{X}$                                            | 特征矩阵                         | $N \times D$      |
| $D$                                                     | 特征总维度                        | 约 490             |
| $\tilde{x}_t$                                           | 标准化后的特征值                     | —                 |
| $p_t^{\text{ext}}$                                      | 第 $t$ 分钟属于极端行情的预测概率          | $[0, 1]$          |
| $\hat{g}_t^{\text{normal}}, \hat{g}_t^{\text{extreme}}$ | 正常/极端回归器的预测收益率               | —                 |
| $\mathcal{L}_\delta$                                    | Huber 损失函数                   | $\delta$ 为参数      |
| IC                                                      | 信息系数 (皮尔逊相关系数)               | $[-1, 1]$         |

## 4 特征设计

特征设计是整个预测流程的基石。我们从最原始的 OHLCV 数据出发，采用固定窗口滚动计算的方式，逐分钟产生对应的特征向量，严格遵守在每一个时间截面上仅使用当前及过去信息的原则。为了同时捕捉短期波动和中期趋势，我们选取了 7 个不同的回顾周期：5 分钟、10 分钟、20 分钟、30 分钟、60 分钟、120 分钟和 240 分钟。对每一个选定的周期，我们独立地计算一组涵盖价格、成交量、波动以及微观结构多个维度的统计量，最后将七个周期得到的特征向量横向拼接，构成一个约 490 维的高维特征空间。

在最为基础的价格与成交量特征层面，对于每个周期内的窗口数据，我们首先计算了基于收盘价的对数收益率和累计收益率，同时统计了窗口内的实现波动率（收益率标准差）以及正收益所占的比例，以反映市场方向性。描述收盘价自身分布的统计量，如均值、标准差、最小值、最大值、中位数、区间占比（最高最低价差除以最低价）、偏度和峰度，也被纳入其中，用以捕捉价格的集中位置、离散程度、分布形态和厚尾风险。成交量方面，我们提取了窗口内的成交量均值、标准差、当前成交量相对于均值的比值和 Z-score、成交量的偏度与峰度，以及窗口首尾时刻的成交量变化率，这些特征有助于刻画市场参与热度和流动性边际变化。与此同时，我们引入了高低价差的均值与标准差、基于真实波幅（ATR）计算的平均真实波动与波动程度，以及 K 线的上影线和下影线平均长度，从波动范围和蜡烛图形状两个角度进一步丰富信息。

在技术指标层面，我们参照经典的技术分析方法，构造了以下类别的特征。一是移动平均类，包括当前收盘价相对于简单移动平均（SMA）和指数移动平均（EMA）的偏离度，用于衡量价格在短期内的相对位置。二是振荡器类，如相对强弱指数（RSI）、KDJ 指标的 K、D、J 值和 MACD 的快线、慢线及柱线。这些指标源于对价格动量和超买超卖状态的刻画，常被用来判断趋势反转或延续。三是通道类指标，即布林带的带宽、%b（收盘价在带内的相对位置）和相对于中轨的 Z-score，它们从统计学角度衡量价格是否处于极端区域。此外，我们还计算了价格突破窗口最高价和最低价的幅度，以及相邻 K 线之间跳空缺口的大小，用以发现潜在的价格突变信号。

为了更精准地描述高频交易环境下的微观结构行为，我们进一步引入了一批高级特征。成交量加权均价（VWAP）以及当前收盘价与 VWAP 的比率和 Z-score，反映了成交量的价格重心与当前价格的偏离，被视为机构交易行为的代理变量。价格变动与成交量变动的滚动相关系数，以及收益率绝对值超过两倍滚动标准差的样本占比（尾部比率），则可分别用于检测量价关系的转变和尾部风险的积累。上行波动率与下行波动率的非对称性指标、

连续上涨与下跌的比例，反映了市场推力和压力的不对等。价格相对于窗口内最高点的回撤幅度和相对于最低点的回升幅度，刻画了路径依赖特征。除了标准的实现波动率外，我们还计算了帕金森波动率和 Garman-Klass 波动率，这两种波动率估计方法利用了日内最高价和最低价的信息，在理论上比单纯基于收盘价的估计更有效。最后，收益率的一阶差分（收益率加速度）、短期波动率与长期波动率的比值、量价趋势背离度、收益率分布的凸性以及短期收益率的偏度等特征，也被纳入特征集合中，以期捕捉市场转折和波动加剧前的细微前兆。

为避免量纲差异影响模型训练，所有特征均经过严格的滚动 Z-score 标准化。标准化窗口固定为 240 分钟，仅使用过去  $w$  分钟的特征值计算均值和标准差，数学表达为

$$\tilde{x}_{t,i} = \frac{x_{t,i} - \mu_{t-w:t-1,i}}{\sigma_{t-w:t-1,i} + \epsilon}, \quad (1)$$

其中  $\mu$  和  $\sigma$  分别是特征  $i$  在过去  $w$  分钟内的均值和标准差， $\epsilon = 10^{-9}$  用于避免除零。这一操作完全基于历史信息，因此可以无缝部署到在线预测环境中。鉴于 LightGBM 本身就具备特征重要性的自动评估机制，我们没有预先进行线性降维（如 PCA），而是让模型在训练过程中自主筛选对预测收益贡献较大的特征，并通过输出增益和分裂次数来辅助事后的特征重要性分析。

## 5 预测模型的建立

### 5.1 基准模型

我们采用 LightGBM 作为核心回归器。LightGBM 是一种基于梯度提升决策树的集成学习框架，采用直方图算法和叶子节点生长策略，在高维数据下不仅训练速度快、内存消耗低，而且对特征的共线性和缺失值表现出良好的鲁棒性。对于给定的特征矩阵  $\mathbf{X}$ ，我们的目标是学习一个函数  $f(\mathbf{X})$  来逼近真实收益率  $y$ ，通过最小化损失函数来实现：

$$\min_f \sum_i L(y_i, f(\mathbf{x}_i)) + \Omega(f), \quad (2)$$

其中  $L$  为损失函数， $\Omega(f)$  代表模型复杂度的正则化项。考虑到金融收益率数据中经常出现异常值，我们选择 Huber 损失作为基础损失函数，它在误差较小时采用平方损失，在误差较大时转为线性损失，从而兼具 MSE 的高效性和 MAE 的稳健性：

$$L_\delta(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2, & |y - \hat{y}| \leq \delta, \\ \delta(|y - \hat{y}| - \frac{1}{2}\delta), & \text{其他}. \end{cases} \quad (3)$$

根据经验，我们为 5 分钟收益率预测设置  $\alpha = 0.9$  的 Huber 参数，为 60 分钟预测设置  $\alpha = 0.85$ ，以在保留预测精度和抑制噪声之间取得适合各自时间尺度的平衡。

### 5.2 兼顾普通与极端行情的融合框架

为实现题目明确提出的“兼顾普通行情和极端行情”要求，我们设计了一种先识别、后分离建模、再概率融合的双阶段框架。该框架的核心思想是：极端行情与普通行情的生成机制可能存在本质差异，若使用单一模型强行拟合所有状态，则模型可能会被样本量占优的普通行情主导，而在极端行情下表现不佳；但若简单地将数据硬性切分为正常和极端两部分并各自独立建模，又会在预测时面临“不知道当前属于哪种状态”的困境。

为此，我们首先训练一个独立的极端行情分类器，该分类器同样使用 LightGBM，以是否处于预先标注的极端区间为二分类标签，输出当前时刻属于极端行情的概率  $p_t^{\text{ext}}$ 。为平衡拟合能力与泛化性，分类器采用适度正则化：叶子数 15，最大深度 4，最小叶节点样本数 200，L1 正则系数 3.0，L2 正则系数 5.0，特征采样比例 0.4，样本采样比例 0.5。分类器以 AUC 为评价指标，在本地验证集上取得了 0.912 的 AUC，表明其对极端行情具有优良的识别能力。

在此基础上，我们为 5 分钟收益率分别训练两个专门的回归器：正常回归器仅使用非极端样本训练，极端回归器仅使用极端样本训练。为了进一步引导模型重视尾部风险，训练时对极端样本赋予了 3 倍的样本权重。预测阶段，我们并不直接选择某一路径，而是通过概率加权将两支预测融合：

$$\hat{y}_t = (1 - p_t^{\text{ext}}) \cdot \hat{y}_t^{\text{normal}} + p_t^{\text{ext}} \cdot \hat{y}_t^{\text{extreme}}. \quad (4)$$

当  $p_t^{\text{ext}}$  较低时，预测主要信赖正常回归器；当极端概率升高时，极端回归器的权重相应增加，实现两种状态下知识的软性过渡。对于 60 分钟收益率，考虑到长周期预测本身就存在较大的不确定性，且极端样本的数量相对稀少，若强行分离建模容易因训练数据不足而导致严重过拟合，因此我们对其采用全量数据训练一个统一的 Huber 回归器，不再进行分离融合。

### 5.3 多时间尺度和多标的处理

针对题目要求的 5 分钟和 60 分钟两个预测目标，我们分别为它们建立独立的模型组，两组模型使用完全相同的一套特征输入，但目标变量和模型结构按上述策略分别配置。在多市场多标的层面，我们将 30 支高波动标的的所有样本混合在一起进行训练，让 LightGBM 通过学习全量数据来捕捉跨标的的共性模式。虽然不同标的可能具有某些个体特性，但高波动资产在市场剧烈运动时的行为往往表现出较强的共性（例如波动率同步放大、流动性骤减等），因此统一建模已可提供相当不错的泛化能力。我们没有显式地将标的的标识作为特征输入，这样既保持了模型的简洁，也避免了因标的数量较多而导致的维数膨胀。若未来需要进一步考虑标的的个性化，可在此基础上通过迁移学习或多任务学习等方式进行扩展。

## 6 模型的求解与训练

### 6.1 数据预处理与划分

在特征生成之前，我们对原始 OHLCV 数据进行了必要的清洗：所有非数值和缺失值被统一置零，所有涉及除法的运算均在分母上添加极小量  $\epsilon = 10^{-9}$ ，并将运算中出现的无穷和 NaN 统一替换为零。生成的特征矩阵随后经过前述滚动 Z-score 标准化。收益率标签方面，为了降低个别极端收益率对损失函数的过度影响，我们对 Ret5 和 Ret60 的标签分别进行了上下 0.5% 的缩尾处理，即将超出分位数的值截断到对应边界。

训练集和验证集的划分严格遵循时间顺序，以模拟真实的实时预测场景。对每一支标的，我们取时间轴上前面 80% 的分钟作为训练候选集，后面 20% 作为验证集，并在两者之间引入长度为 30 分钟的间隔（purge），即丢弃训练集末尾 30 分钟和验证集开头 30 分钟的数据。这一设计能有效避免相邻样本的标签自相关导致的评估偏乐观，确保验证集预测完全基于不重叠的信息段。在训练时，我们采用分片训练策略，即每次只加载一支标的的特征和标签，训练完成后立即释放内存，再处理下一支标的，这样即使面对海量高频数据也能在有限内存条件下完成训练。

## 6.2 训练细节与超参数

所有 LightGBM 模型的超参数统一保存在配置文件中，回归模型的共同设置包括：学习率为 0.05，树的最大深度为 8，单棵树的叶子节点数为 31，特征采样比例和样本采样比例均为 0.8，L1 和 L2 正则化项系数分别为 0.01 和 0.1。极端分类器则采用前述更强正则化设置。训练最大迭代轮数为 300 轮，在验证集上监控信息系数 (IC)，当连续 20 轮未提升时触发早停。最终，我们将每支标的训练得到的模型以字符串形式保存，并在总控模型中记录下它们的平均最佳迭代轮数，便于预测时加载。

## 6.3 预测结果与特征重要性

在本地分片验证集上，我们汇总了所有标的的 out-of-fold 预测值，分别计算正常行情和极端行情下的信息系数 (IC)，结果汇总于表2。可以看出，极端行情下的 IC 明显优于普通行情，尤其是 60 分钟收益率的极端 IC 达到了 0.182，表明模型对剧烈波动时段的长周期预测具有较强的能力；5 分钟极端 IC 也达到 0.073，验证了分离融合策略的有效性。普通行情下 IC 接近零或为负，说明在市场平稳时收益率的可预测性本身较弱，模型较难捕捉到稳健的线性关系，这与高波动资产在平静期的低信噪比特征相符。

表 2: 本地验证集预测性能 (聚合 IC 与 AUC)

| 目标    | 正常行情 IC | 极端行情 IC | 极端分类器 AUC |
|-------|---------|---------|-----------|
| Ret5  | -0.025  | 0.073   | 0.912     |
| Ret60 | 0.002   | 0.182   | —         |






图 1: 极端行情分类器 ROC 曲线与 AUC



(a) Ret5 模型正常与极端行情 IC 对比



(b) Ret60 模型正常与极端行情 IC 对比

图 2: IC 对比图

### 6.3.1 可视化分析

为了更直观地展示模型性能，本节给出关键模型的可视化结果。图1展示了极端行情分类器在验证集上的 ROC 曲线，AUC 达到 0.9118；图3给出了分类器输出的极端概率分布直方图，可以看出概率值大量集中在 0 和 1 两端，表明分类器具有较高的置信度。






图 3: 极端行情分类器预测概率分布直方图

对于 5 分钟收益率分离融合模型，图2a对比了正常与极端行情下的信息系数，图5a展示了特征重要性（平均增益），图4a绘制了 OOF 预测值与真实标签的散点图。从图5a可以看出，KDJ 指标的 K、D 值在分离模型中获得了相对较高的增益，说明动量类指标对短期极端收益具有一定预测能力。

对于 60 分钟统一回归模型，图2b显示了正常与极端行情下的 IC，图5b给出了特征重要性（增益），图4b为 OOF 散点图。从图5b可以看出，长周期波动率、量价相关性及价格回撤等微观结构特征占据了主导地位，验证了第 4 节特征设计的合理性。



(a) Ret5 模型 OOF 预测值与真实标签散点图



(b) Ret60 模型 OOF 预测值与真实标签散点图

图 4: OOF 预测散点图

特征重要性方面，Ret5 和 Ret60 模型由于结构差异，呈现出截然不同的特征利用模式。Ret5 采用了正常/极端分离回归器，训练结束后我们分别对两个回归器的特征增益进行平均。但正常回归器和极端回归器所关注的特征子集几乎完全正交，导致平均后大部分特征的增益接近零，仅有少数特征保持了非零增益。这一点在表3中得到体现：排名前三的特征均为 KDJ 指标的 K、D 值（周期 20、30），说明在 5 分钟尺度下，动量型技术指标对正常或极端行情的短期预测仍有一定贡献，但由于特征使用高度分化，整体平均增益极低。

相比之下，Ret60 使用全量数据训练的统一 Huber 回归器，特征重要性分布更加合理和集中。表4列出了增益最高的十个特征，其中以长周期波动率、量价相关性和价格路径特征为主导。排名第一的 price\_vol\_corr\_240（价格-成交量相关系数）增益高达 5.961，runup\_240（价格自低点的回升幅度）和 autocorr1\_120（收益率自相关）紧随其后，分别为 5.509 和 3.871。此外，hl\_mean\_120、ret\_density\_120、abs\_ret\_q90\_ratio\_240 等特征也进入了前六，表明在高波动环境下，极端收益率的可预测性主要源于波动范围、极端收益密度以及收益率分布的厚尾特征。这些发现与我们的特征设计初衷高度一致，也验证了微观结构特征在长周期极端行情预测中的核心地位。


表 3: Ret5 模型特征重要性 Top 3（正常/极端回归器平均增益）

| 排名 | 特征名称       | 增益    |
|----|------------|-------|
| 1  | k_value_20 | 0.030 |
| 2  | d_value_20 | 0.009 |
| 3  | k_value_30 | 0.008 |




表 4: Ret60 模型特征重要性 Top 10 (统一回归器增益)

| 排名 | 特征名称                  | 增益    |
|----|-----------------------|-------|
| 1  | price_vol_corr_240    | 5.961 |
| 2  | runup_240             | 5.509 |
| 3  | autocorr1_120         | 3.871 |
| 4  | hl_mean_120           | 2.906 |
| 5  | ret_density_120       | 2.834 |
| 6  | abs_ret_q90_ratio_240 | 2.773 |
| 7  | ret_240               | 2.770 |
| 8  | (下略)                  | ...   |



(a) Ret5 模型特征重要性 (Top 20, 平均增益)



(b) Ret60 模型特征重要性 (Top 20, 增益)

图 5: 特征重要性对比

## 7 模型检验与分析

### 7.1 评价指标

我们以信息系数 (IC) 作为核心评价指标, 即预测值与真实值之间的皮尔逊相关系数。同时分别考察正常行情和极端行情子集上的 IC, 以评估模型在不同市场状态下的表现。对于极端分类器, 采用 AUC 衡量其区分能力。

### 7.2 对比实验

为检验所提各组件的作用, 我们设计并运行了若干消融实验。

首先, 将完整的分离融合模型与仅使用统一回归器的基准进行对比, 基准模型在极端 IC 上出现了明显下降 (5 分钟极端 IC 从 0.073 降至约 0.038), 这证实了分离建模对提升极端行情预测能力的必要性。

其次, 我们移除了对极端样本的 3 倍加权, 发现极端 IC 再次下滑, 表明针对性加权能有效引导模型重视尾部样本。

此外, 若不进行收益率标签的缩尾处理, 普通 IC 略有提高, 但极端 IC 出现大幅震荡, 说明缩尾在牺牲少量普通样本拟合度的前提下换取了更稳健的极端预测。

若去除训练集/验证集之间的 30 分钟 purge 间隔, 验证 IC 看似更高, 但实则为标签自相关导致的虚假提升, 保留 purge 是保证评估真实性的关键。整体来看, 我们的每一项设计都对最终的均衡性能产生了正面贡献。

### 7.3 灵敏度分析

我们对几个关键参数进行了灵敏度测试。固定其他参数，将滚动标准化窗口  $w$  在 120 至 480 分钟之间调整，发现模型 IC 在 240 分钟附近达到峰值，过短的窗口会使标准化不稳定，过长则反应迟缓。对于 Huber 损失中的分位数参数  $\alpha$ ，在 0.8 至 0.95 之间微调，5 分钟预测的 IC 变化幅度在 0.01 以内，表明模型对  $\alpha$  选择具有一定的鲁棒性。极端分类器的概率融合权重若从软概率改为硬分类（取  $p_t^{\text{ext}}$  二值化），整体 IC 进一步降低，表明软融合过渡的平滑性对保持预测稳定性至关重要。

### 7.4 极端行情下的预测能力专项评估

我们将验证集中所有被标注为极端行情的分钟单独提取，计算其 IC。即使在这些剧烈波动的时段里，模型仍然保持了正向且较高的 IC 值（5 分钟 0.073，60 分钟 0.182），且显著高于普通行情下的 IC，表明我们的分离融合框架确实有效地捕捉到了极端行情中的预测信号，尤其在中长周期预测上展现出了较强的能力。

## 8 模型的评价与推广

### 8.1 模型优点

本文提出的预测框架具有以下几个突出优点。

第一，严格的时序处理贯穿始终，从特征计算、标准化到训练验证集划分，均未引入未来信息，完全符合实时交易的要求。

第二，通过极端分类器与分离回归的概率融合，模型能够智能地识别市场状态并切换预测模式，在极端行情下展现出远优于普通行情的预测能力，特别是 60 分钟极端 IC 高达 0.182。

第三，得益于 LightGBM 的高效性和分片训练策略，整个训练过程能够在普通计算设备上完成，且只需较少的运行内存。

第四，特征体系设计全面、多尺度覆盖，且特征重要性分析（尤其是 Ret60）清晰地展示了波动率和微观结构特征的核心作用，具有较强的可解释性。

### 8.2 模型缺点

模型也存在一些不足之处。

首先，极端行情的定义依赖于事先标注的区间，如果标注本身存在偏差或与真实风险事件对应不佳，将直接影响分类器的训练质量和后续融合效果。

其次，LightGBM 作为树模型虽然善于处理表格型数据，但无法像循环神经网络或 Transformer 那样显式地捕获远距离时间依赖，一些需要长期记忆的市场模式可能被遗漏。

此外，目前我们没有显式地对多标的之间的关系进行建模，标的之间的相互影响（例如风险传染）未被利用。

从本地验证结果看，普通行情下 IC 接近零或为负，说明模型在平稳市场中的预测能力有限，后续需要加强特征对平静期微弱信号的捕捉能力。Ret5 模型的特征重要性分布也反映出分离建模虽然提升了极端性能，却牺牲了全局特征重要性的可读性，未来可探索更统一的特征使用策略。

### 8.3 改进方向与推广应用

针对上述局限，后续可以从以下几个方向进行改进。在模型结构方面，可以尝试引入 PyTorch 框架下的 LSTM 或 Transformer 作为时序特征提取器，与树模型形成互补，或者

在符合评测平台支持的条件下直接采用深度梯度提升模型。在多标的建模上，可探索多任务学习或图神经网络，将标的之间的相关性作为额外信息输入。在极端行情识别上，可以结合无监督方法或自适应阈值来提高标注的泛化性。此外，本文的框架不仅限于收益率预测，只需替换目标变量，即可推广到波动率预测、涨跌方向分类或极端风险预警等任务，具有一定的通用价值。

## 9 结论

本文以 30 支高波动标的的 1 分钟 OHLCV 数据为研究对象，针对未来 5 分钟和 60 分钟收益率的预测问题，提出了一套兼顾普通行情与极端行情的完整解决方案。在特征工程层面，通过引入多周期量价特征、技术指标和丰富的微观结构特征，构建了约 490 维的信息表征；在模型层面，设计了极端分类器加分离回归的概率融合框架，并辅以样本加权和 Huber 损失，有效提升了模型在极端市场条件下的预测能力。本地分片验证集上的实验结果表明，极端分类器 AUC 达到 0.912，5 分钟极端 IC 为 0.073，60 分钟极端 IC 更是达到 0.182，充分说明了模型对剧烈波动的预测有效性；而在普通行情下 IC 较弱（5 分钟-0.025，60 分钟 0.002），也如实反映了平稳市场中收益率预测的固有难度。特征重要性分析揭示了 Ret60 中波动率和微观结构特征的核心作用，以及 Ret5 分离建模导致的特征使用分化现象。消融实验和灵敏度分析进一步验证了各组件的有效性和参数设置的合理性。本文的工作为高频环境下的收益率预测提供了一种实用且可解释的方案，其设计思想和核心框架具备良好的可推广性。

## 参考文献

- [1] Ke G, Meng Q, Finley T, et al. LightGBM: A highly efficient gradient boosting decision tree. Advances in neural information processing systems, 2017.
- [2] Parkinson M. The extreme value method for estimating the variance of the rate of return. Journal of Business, 1980.
- [3] Garman M B, Klass M J. On the estimation of security price volatilities from historical data. Journal of business, 1980.
- [4] 竞赛组委会，C 题收益率预测问题数据说明及评测平台文档。

## A 特征生成脚本说明

特征生成的核心功能由 `feature_generation.py` 实现,其对外接口函数为 `build_features_from_oh`。接收一个  $N \times 5$  的 OHLCV 矩阵和窗口长度,返回对应窗口末尾分钟的特征矩阵和时间索引。内部采用多周期并行设计,对每个回顾周期 (5、10、20、30、60、120、240 分钟) 调用 `_window_feature_block` 计算基础统计量、技术指标和微观结构特征,最终将所有周期特征横向拼接为约 490 维的特征向量。所有特征计算均使用 Pandas 滚动窗口实现向量化,保证效率。`apply_preprocessing` 函数则对特征矩阵执行滚动 Z-score 标准化,仅依赖历史信息。

评测平台要求提交的 `factor.py` 是特征生成环节的入口脚本,它封装了上述底层逻辑。其中的 `generate_factors` 函数接受数据集名称和 OHLCV 原始数据,调用 `build_features_from_oh` 后,将特征按照原始时间轴对齐,生成一个完整长度的特征矩阵 (缺失位置填充为 NaN),返回 float32 类型的结果。该脚本同时支持命令行直接运行,便于本地调试与验证。

## B 模型核心代码与参数文件

训练脚本 `train_model.py` 实现了分片训练流程。对每个标的,按 8:2 比例划分训练和验证集,并在两者间保留 30 分钟 `purge` 间隔。训练过程分为两步:首先训练一个适度正则化的极端行情分类器 (叶子数 15、最大深度 4、 $L1=3.0$ 、 $L2=5.0$ 、特征采样 0.4、样本采样 0.5),再训练分离回归器。所有模型最大迭代 300 轮,早停 20 轮。最终保存为 `lgb_model.joblib`,包含子模型字符串、预处理参数及特征维度。

预测脚本 `predict.py` 是整个建模流程的最终产出,负责在评测平台上加载训练好的模型并对新数据进行收益率预测。脚本通过 `generate_signals` 函数作为平台入口,接收数据集名称和由 `factor.py` 生成的特征矩阵,内部首先进行缺失值与异常值的安全处理,随后加载模型文件。对于 `ret5` 目标,若模型字典中包含 `normal` 和 `extreme` 两个子模型,则重建极端分类器 `Booster`,对输入特征进行滚动 Z-score 标准化后分别调用正常回归器和极端回归器进行预测,再通过分类器输出的概率进行加权融合;若分类器不可用,退化为等权平均融合。对于 `ret60` 目标,若存在 `full` 模型则直接预测,否则按分离融合流程处理。最终输出  $N \times 2$  的收益率预测 (第一列 5 分钟,第二列 60 分钟)。脚本同时支持命令行调用,可对任意 OHLCV `numpy` 文件完成从特征生成到预测的全流程。